Steven Cortes - T00077070
Andres Castano - T00072778

Taller de Modelos de Lenguaje

Parte A - Calculo manual. Ejercicio 0, 3.1 a 3.7 y 3.12.

Mini-Corpus y convenciones.

Mini-Corpus de entrenamiento (con marcadores; cada linea es una oracion):

1. <s> la ingenieria Si es Para mujeres </s>
2. <s> la ingenieria no es Para mujeres </s>
3. <s> las mujeres Estudian ingenieria </s>
4. <s> mujeres en ingenieria Ciencia y Tecnologia </s>
5. <s> Matilda y Las mujeres en ingenieria </s>

Convenciones: <s> y </s> Se cuentan como Tokens; y N (Tokens) Los incluyen. Bigramas: <s> ... </s>. Trigramas <s><s> ... </s>. En la Perplejidad, M = Palabras predichas = Palabras + </s>; en Cada Paso se muestra: formula -> Sustitucion -> Fraccion -> decimal.

Ejercicio 0 — Tablas de conteo

(a) unigramas, N y V

- N = 28+10 = 38

Token w	c(w)	P(w) = c(w)/N (fraccion)	Decimal
<s>	5	5/38	0.1316
</s>	5	5/38	0.1316
Ingenieria	5	5/38	0.1316
Mujeres	5	5/38	0.1316
la	2	2/38 = 1/19	0.0526
las	2	2/38 = 1/19	0.0526
en	2	2/38 = 1/19	0.0526
es	2	2/38 = 1/19	0.0526
para	2	2/38 = 1/19	0.0526
y	1	2/38 = 1/19	0.0526.
Ciencia	1	1/38	0.0263
Estudian	1	1/38	0.0263

Scanned with CamScanner

Matilda	1	1/38	0.0263
no	1	1/38	0.0263
Si	1	1/38	0.0263
Tengo y tu	1	1/38	0.0263
Total.	38	38/38=1	1.0000

Tipos distintos: 14 Palabras + ∠S7 + ∠/S7. V=16

b) Continuaciones de las historias Pedidas.

C(h) = Numero de Veces Q e h es seguida Por Alguna Palabra (en este Corpus Coincide con su Conteo como unigrama Porque cada Token es seguido Por otro.)

Historia h	c(h)	Continuaciones con su conteo c(h,w)
<s>	5	la: 2, las: 1, matilda: 1, mujeres: 1
mujeres	5	</s>: 2, en: 2, estudian: 1
ingeniería	5	</s>: 2, ciencia: 1, no: 1, sí: 1
las	2	mujeres: 2
en	2	ingeniería: 2
la	2	ingeniería: 2

Ejercicio 3.1 - Trigramas

Ecuación MLE para trigramas (igual que la del bigrama, con una palabra más de contexto):

$$P(W_i | W_{i-2} \cdot W_{i-1}) = C(W_{i-2}\ W_{i-1}\ W_i) / C(W_{i-2}\ W_{i-1})$$

Todas la probabilidades de trigrama no nulas (c(contexto) = número de veces que el par aparece como contexto):

Contexto (W_1, W_2)	$c(W_1\ W_2)$	W_3	$c(W_1 W_2 W_3)$	Fracción	Decimal
<s> <s>	5	la	2	2/5	0.4000
<s> <s>	5	las	1	1/5	0.2000
<s> <s>	5	matilda	1	1/5	0.2000
<s> <s>	5	mujeres	1	1/5	0.2000
<s> la	2	ingeniería	2	2/2=1	1.0000
<s> las	1	mujeres	1	1/1	1.0000
<s> matilda	1	y	1	1/1	1.0000
<s> mujeres	1	en	1	1/1	1.0000
ciencia y	1	tecnología	1	1/1	1.0000
en ingeniería	2	</s>	1	1/2	0.5000
en ingeniería	2	ciencia	1	1/2	0.5000
es para	2	mujeres	2	2/2=1	1.0000
estudian ingeniería	1	</s>	1	1/1	1.0000
ingeniería ciencia	1	y	1	1/1	1.0000
ingeniería no	1	es	1	1/1	1.0000
ingeniería sí	1	es	1	1/1	1.0000
la ingeniería	2	no	1	1/2	0.5000
la ingeniería	2	sí	1	1/2	0.5000
las mujeres	2	en	1	1/2	0.5000
las mujeres	2	estudian	1	1/2	0.5000
matilda y	1	las	1	1/1	1.0000
mujeres en	2	ingeniería	2	2/2=1	1.0000
mujeres estudian	1	ingeniería	1	1/1	1.0000
no es	1	para	1	1/1	1.0000
para mujeres	2	</s>	2	2/2=1	1.0000
sí es	1	para	1	1/1	1.0000
y las	1	mujeres	1	1/1	1.0000
y tecnología	1	</s>	1	1/1	1.0000

Scanned with CamScanner

¿Cuantos Trigramas Distintos hay? 28

¿Cuantos tienen Probabilidad 1 y Porque? 13 son los trigramas cuyo contexto (w1 ... w2) siempre es seguido por la misma palabra: ((w1, w2, w3) = C(w1 w2). Los otros no pertenecen a los 4 contextos donde hay varias continuaciones: (<s>, <s>), (Las mujeres), (mujeres, en), y (en, ingeniería)

Ejercicio 32 → Probabilidad de una oración.

Oración: <s> las mujeres en ingeniería </s>. Se usa el modelo bigrama: P(oración) = Π P(wi | wi-1).

(a) Bigrama sin suavizar (MLE): P(w|h) = C(h w) / C(h)

Factor	Sustitución	Fracción	Decimal
P(las | <s>)	C(<s> las) / C(<s>) = 1/5	1/5	0.2000
P(mujeres | las)	C(las mujeres) / C(las) = 2/2	1	1.0000
P(en | mujeres)	C(las mujeres) / C(mujeres) = 2/5	2/5	0.4000
P(ingeniería | en)	C(en ingeniería) / C(en) = 2/2	1	1.0000
P(</s> | ingeniería)	C(ingeniería </s>) / C(ingeniería) = 2/5	2/5	0.4000

$P_{MLE} = 1/5 \times 1 \times 2/5 \times 1 \times 2/5 = 4/125 = 0.0320$

b) Suavizado add-1 (laPlace): P(w|h) = (C(h w) + 1) / (C(h) + V), con V = 16

Factor	Sustitución	Fracción	Decimal
P(las | <s>)	(1+1) / (5+16) = 2/21	2/21	0.0952
P(mujeres | las)	(2+1) / (2+16) = 3/18	1/6	0.1667
P(en | mujeres)	(2+1) / (5+16) = 3/21	1/7	0.1429
P(ingeniería | en)	(2+1) / (2+16) = 3/18	1/6	0.1667
P(</s> | ingeniería)	(2+1) / (5+16) = 3/21	1/7	0.1429

$P_{add-1} = 2/21 \times 1/6 \times 1/7 \times 1/6 \times 1/7 = 2/37044 = 1/18522 \approx 0.0000540$

Ejercicio 3.3 - ¿Cuál es mayor?

La probabilidad MLE (4/125 = 0.0320) es mayor que la add-1 (1/18522 = 0.0000540). Cociente: (4/125)/(1/18522) = 4 · 18522/125 = 74088/125 = 592.704. La MLE es unas 593 veces mayor.

¿Por qué?: add-1 quita masa de probabilidad a los eventos vistos para repartirla entre los 16 tipos posibles en cada contexto, incluidos los que nunca ocurrirían. En un corpus tan pequeño el efecto es enorme, porque C(h) es chico (2 o 5) y V = 16 es grande en comparación.

Bigrama concreto: P(mujeres | Las) pasa de 2/2 = 1 (MLE) a (2+1)/(2+16) = 1/6 ≈ 0.1667 (add-1). Una caída de 6 veces. Lo mismo ocurre con P(ingeniería | en): de 1 a 1/6. Como la oración usa 5 bigramas, todos estos pérdidas se multiplican.

Ejercicio 3.4 - Add-1 en un bigrama no visto

El bigrama (ingeniería, es) no aparece en el corpus: C(ingeniería es) = 0, y C(ingeniería) = 5.

MLE: P(es | ingeniería) = 0/5 = 0
Add-1: P(es | ingeniería) = (0+1)/(5+16) = 1/21 = 0.0476.

Oración = "la ingeniería es para mujeres" = sin suavizar: contiene el bigrama (ingeniería, es) cuya probabilidad es 0. Como la probabilidad de la oración es un producto, P(oración) = 0 aunque la oración sea perfectamente razonable. Su perplejidad sería infinita. Un modelo MLE no puede asignar probabilidad a nada que no haya visto en el entrenamiento.

Ejercicio 3.5 → Sin el símbolo </s>

Entrenamiento: (Sin </s>): </s> mujeres ingenieras : </s>
Ingeniera mujeres </s> mujeres mujeres. Sea M = mujeres,
I = ingeniera. Aquí c(h) es el número de veces que h es
seguida por una palabra (La última palabra de cada oración
no tiene siguiente).

Historia h	c(h)	Continuaciones	Probabilidades MLE
</s>	4	M:2, I:2	P(M | </s>) = 2/4 = 1/2; P(I | </s>) = 2/4 = 1/2
mujeres	2	I:1, M:1	P(I | M) = 1/2; P(M | M) = 1/2
ingeniera	2	I:1, M:1	P(I | I) = 1/2; P(M | I) = 1/2.

Ejercicio 3.6 – Trigrama con add-1

$$P_{add-1}(w_3 \mid w_1, w_2) = \frac{c(w_1\, w_2\, w_3) + 1}{c(w_1\, w_2) + V}$$

Contexto (La ingeniera): C(La ingeniera) = 2; Sus continuaciones son
<<si>> (1) y <<no>> (1). V = 16.

Cantidad	Sustitución	Fracción	Decimal
P_add-1(si | La ingeniera)	(1+1)/(2+16) = 2/18	1/9	0.1111
P_MLE(si | La ingeniera)	1/2	1/2	0.5000
P_add-1(es | La ingeniera)	(0+1)/(2+16) = 1/18	1/18	0.0556
P_MLE(es | La ingeniera)	0/2	0	0.0000

Comparación: Para el trigrama visto (si), add-1 baja la probabilidad de 1/2 a 1/9; para el no visto (es), la sube de 0 a 1/18. El denominador usa V = 16, que es grande frente a C(La ingeniera) = 2.

Ejercicio 3.7 - interpolación lineal.

$P(w|h) = \lambda_1 P_{MLE}(w) + \lambda_2 P_{MLE}(w|h)$, con $\lambda_1 = \lambda_2 = 1/2$

Para $P(en|mujeres)$: $P_{MLE}(en) = C(en)/N = 2/38 = 1/19$:

$P_{MLE}(en|mujeres) = C(mujeres\ en)/C(mujeres) = 2/5$.

$P = 1/2 \times 1/19 + 1/2 \times 2/5 = 1/38 + 1/5 = (5+38)/190$

$= 43/190 = 0.2263$

Ejercicio 3.12 - Perplejidad.

Perplejidad: $PP(w) = P(w)^{-1/n}$.

a) Unigrama.

Entrenamiento: 100 Palabras, 91 veces <<mujeres>> y 1 vez

Cada una de otras 9. Por tanto $P(mujeres) = 91/100 = 0.91$

y $P(matilda) = 1/100 = 0.01$. Prueba: mujeres x5, matilda,

mujeres x4 -> 9 veces...

Scanned with CamScanner

«mujeres» 4 veces «matilda», M=10

$P(\text{prueba}) = 0.91^9 \times 0.01$

$\ln P = 9 \cdot \ln(0.91) + \ln(0.01) = 9 \cdot (-0.09431) + (-4.60517) = -5.45397$

$PP = \exp(5.45397/10) = \exp(0.545397) = 1.7253$

Interpretación: una perplejidad de 1.73 significa que el modelo se comporta como si en cada posición tuviera que elegir entre unas 1.7 palabras equiprobables. Es muy baja porque la prueba está dominada por la palabra más frecuente del entrenamiento: sabe «matilda», con probabilidad 0.01, la sabe

(b) Bigrama sobre «<s> las mujeres en ingeniería </s>» (resultados del ejercicio 3.2)

M=5 palabras predichas (las, mujeres, en, ingeniería, </s>).

Modelo	Fórmula y sustitución	Resultado
MLE	$PP=(4/125)^{(-1/5)}=(31.25)^{(1/5)}=\exp(\ln 31.25/5)=\exp(3.4420/5)=\exp(0.6884)$	1.9905
Add-1	$PP=(1/18522)^{(-1/5)}=(18522)^{(1/5)}=\exp(\ln 18522/5)=\exp(9.8267/5)=\exp(1.9653)$	7.1374

Interpretación: add-1 duplica con creces la perplejidad (1.99 → 7.14) porque le quita masa a los bigramas vistos. El modelo MLE «sabe» mucho de esta oración porque está en el corpus, pero fallaría con cualquier oración nueva (perplejidad infinita, ejercicio 3.4); add-1 pierde precisión pero siempre da un valor finito.

Scanned with CamScanner